



**Universidad Nacional Autónoma de México**  
**Escuela Nacional de Estudios Superiores**  
**Unidad Morelia**



Proyecto Final  
**Predicción del Crecimiento Significativo en Plantas**

PRESENTA:

**Alexis Uriel Aguilar Uribe**

PROFESORES:

**Dra. Marisol Flores Garrido**

**Dr. Luis Miguel García Velázquez**

GRADO

**Licenciatura en Tecnologías para la Información en Ciencias**

**Número de Cuenta:** 424060075

**Asignatura:** Sistemas basados en conocimiento [Machine Learning]

**A:** 27 de Mayo del 2025

# Índice

<b>1. Introducción</b>	<b>2</b>
<b>2. Descripción de los Datos</b>	<b>3</b>
<b>3. Análisis Exploratorio de Datos</b>	<b>5</b>
3.1. Atributos Numéricos . . . . .	5
3.2. Atributos Categóricos . . . . .	7
<b>4. Metodología del Proyecto</b>	<b>10</b>
4.1. Preprocesamiento . . . . .	10
4.2. Modelos de Machine Learning . . . . .	11
<b>5. Experimentos y Discusión de Resultados</b>	<b>12</b>
<b>6. Análisis de los Resultados</b>	<b>13</b>
<b>7. Conclusiones</b>	<b>14</b>
<b>Referencias Bibliográficas</b>	<b>15</b>

# 1. Introducción

En la agricultura, como cualquier otra industria, se vuelve relevante la optimización de los recursos y ganancias, es decir, reducir los insumos consumidos mientras se incrementa la producción (tanto en calidad como en cantidad); todo lo anterior se traduce en aplicar mejoras en diferentes áreas y aspectos que convergen y se relacionan para generar ganancias y reducir costos en la agricultura. Para el caso de este proyecto, el interés se encuentra en el crecimiento de las plantas, bajo qué factores ambientales y de cuidado propician un crecimiento significativo en las plantas.

Para lograr el último punto, se tiene como objetivo el crear un modelo de aprendizaje supervisado para la clasificación del crecimiento significativo en base a los factores y mediciones relacionadas a su cuidado y ambiente. Esto se encuentra desarrollado en el repositorio en GitHub dedicado para el proyecto: Plant Growth Model.

## 2. Descripción de los Datos

El conjunto de datos que se emplearán para el proyecto se encuentra disponibles en [1], que es un conjunto de datos publicados en Kaggle por la propia comunidad. Se cuenta con siete columnas, donde seis de ellas son atributos y la otra el target, referenciando a la fuente del conjunto de datos, se tienen los siguientes atributos junto con su descripción y tipo de dato:

- **Soil\_Type** [*String*]: El tipo o composición del suelo en el que las plantas están creciendo o se plantan.
- **Sunlight\_Hours** [*Float*]: La duración o intensidad de la luz solar que las plantas reciben.
- **Water\_Frequency** [*String*]: Qué tan seguido se riegan las plantas, se indica la frecuencia del riego.
- **Fertilizer\_Type** [*String*]: El tipo de fertilizante usado para nutrir a las plantas.
- **Temperature** [*Float*]: Las condiciones de la temperatura ambiental bajo las cuales las plantas están creciendo.
- **Humidity** [*Float*]: El nivel de humedad en el ambiente alrededor de las plantas.
- **Growth\_Milestone** [*Integer, Target*]: Descripción o marcadores que indican la etapa o eventos significativos en el proceso de crecimiento de las plantas.

Por último, el conjunto de datos consta de 193 instancias (filas), las diferentes instancias lucen de la siguiente manera:

Soil_Type	Sunlight_Hours	Water_Frequency	Fertilizer_Type
sandy	9.228	daily	none
sandy	9.774	weekly	chemical
clay	7.392	bi-weekly	none
clay	6.462	bi-weekly	organic
clay	8.846	weekly	organic
loam	5.985	bi-weekly	chemical

Temperature	Humidity	Growth_Milestone
33.804	32.815	0
32.549	61.377	1
31.100	68.600	0
27.517	34.175	1
27.700	56.800	1
29.757	57.476	0

### 3. Análisis Exploratorio de Datos

Los tipos de datos en base a la descripción proporcionada en [1] con la mostrada al momento de la lectura de los datos en Python, por lo que no es necesario realizar una transformación sobre los tipos de datos de cada atributo.

Debido a que los valores que toma y representan el target, *Growth\_Milestone*, son enteros, se tiene que el modelo que se generará será un clasificador binario; cuyas clases representan si hay un crecimiento significativo, bajo ciertos criterios, en las plantas. Como primera observación se tiene que el conjunto de datos está balanceado respecto a las clases, por lo que se podría usar cualquiera de las métricas bajo una justificación válida o apropiada al problema:

Growth_Milestone	
Clases	Conteo
0 [No Milestone]	97
1 [Milestone]	96

Se presenta un análisis univariado sobre los atributos numéricos y categóricos, y por último se prueban algunas hipótesis relevantes y relacionadas sobre las observaciones en los apartados anteriores.

#### 3.1. Atributos Numéricos

Generando la descriptiva básica (medidas centrales y de dispersión) de los datos se obtienen los siguientes resultados:

Medida	Sunlight_Hours	Temperature	Humidity
Media	6.8264	25.0760	58.0989
Desviación Estándar	1.5995	5.3541	12.6317
Mínimo	4.0331	15.2000	30.5676
$Q_1$	5.4770	20.6370	49.3000
$Q_2$	6.8332	25.9123	59.1828
$Q_3$	8.2411	29.7579	69.1000
Máximo	9.9139	34.8101	79.6482

Primero se destaca que siguen diferentes rangos de valores, por lo que se tendrán que estandarizar o blanquear para su adecuado uso para el entrenamiento de los modelos que se crearán, además de permitir realizar comparativas entre las distribuciones. Al estandarizar los valores se tienen los siguientes resultados:

Medida	Sunlight_Hours	Temperature	Humidity
Media	0	0	0
Desviación Estándar	1	1	1
Mínimo	-1.746	-1.8445	-2.1795
$Q_1$	-0.843	-0.8290	-0.6965
$Q_2$	0.004	0.1561	0.0858
$Q_3$	0.884	0.8744	0.8709
Máximo	1.930	1.8180	1.7059

Destacándose que el atributo *Sunlight\_Hours* figura que sigue una distribución debido a que su  $Q_2$  se aproxima a 0 junto que sus  $Q_1$  y  $Q_3$  se parecen, salvo el signo. Mientras que en *Humidity* su  $Q_2$  se encuentra equidistante a  $Q_1$  y a  $Q_3$ , lo que significa que no tiene sesgo más no es simétrica. Y en *Temperature*, por sus cuartiles, tiene un sesgo negativo considerable. En base a lo mencionado se tiene que los tres atributos siguen diferentes distribuciones, implicando que estos atributos surgen de diferentes fenómenos, interacciones y procesos que impactan en el crecimiento de las plantas, por lo que los tres atributos se vuelven relevantes para la clasificación debido a que cada uno condensa diferentes procesos para lograr un crecimiento significativo.

De los box plots, se puede observar que las distribuciones de los atributos no son tan diferentes según el target, según si hay un crecimiento significativo, esto al ver que las cajas están superpuestas, haciendo que no exista una diferencia Significativa entre las medias de las distribuciones. Lo que se destaca es que cuando existe un crecimiento significativo tiende a tomar valores más bajos y además de que su desviación estándar también tiende a decrecer.

Este último hecho se podría relacionar con que existe un control sobre los factores ambientales, haciendo que las distribuciones sean más restrictivas y reguladas, dejando afuera posibles fenómenos que generen un ambiente irregular para el crecimiento de las propias plantas. Haciendo que la planta esté en un ambiente ideal para su crecimiento pero, por las distribuciones,

existe la posibilidad de que aunque esté en las condiciones idóneas no logre un crecimiento significativo.




Figura 1: Distribución de los atributos Numéricos según el Crecimiento Significativo

De manera visual, no se cuenta con valores atípicos derivados de la Regla del Rango Intercuartil ni valores faltantes, por lo que estos atributos numéricos se encuentran preparados para la fase de entrenamiento.

### 3.2. Atributos Categóricos

Cada atributo categórico tiene tres valores únicos, con las siguientes cantidades y valores:

Soil_Type	Cantidad	Water_Frequency	Cantidad
clay	67	daily	74
sandy	64	bi-weekly	60
loam	62	weekly	59



Fertilizer_Type	Cantidad
none	74
chemical	65
organic	54

Siendo *Soil\_type* el atributo que está más balanceado de los tres, por lo que el modelo tendrá suficientes instancias por cada valor como para distinguir entre los posibles casos donde este atributo sea crítico. Mientras que los otros atributos, *Water\_Frequency* y *Fertilizer\_Type* no están balanceadas en sus valores, esto podría estar relacionado a que no se realizaron los suficientes experimentos para generar todos los posibles resultados por igual o existe un factor que provocara un cierto sesgo o preferencia sobre ciertos valores, como lo son la falta de insumos suficientes.

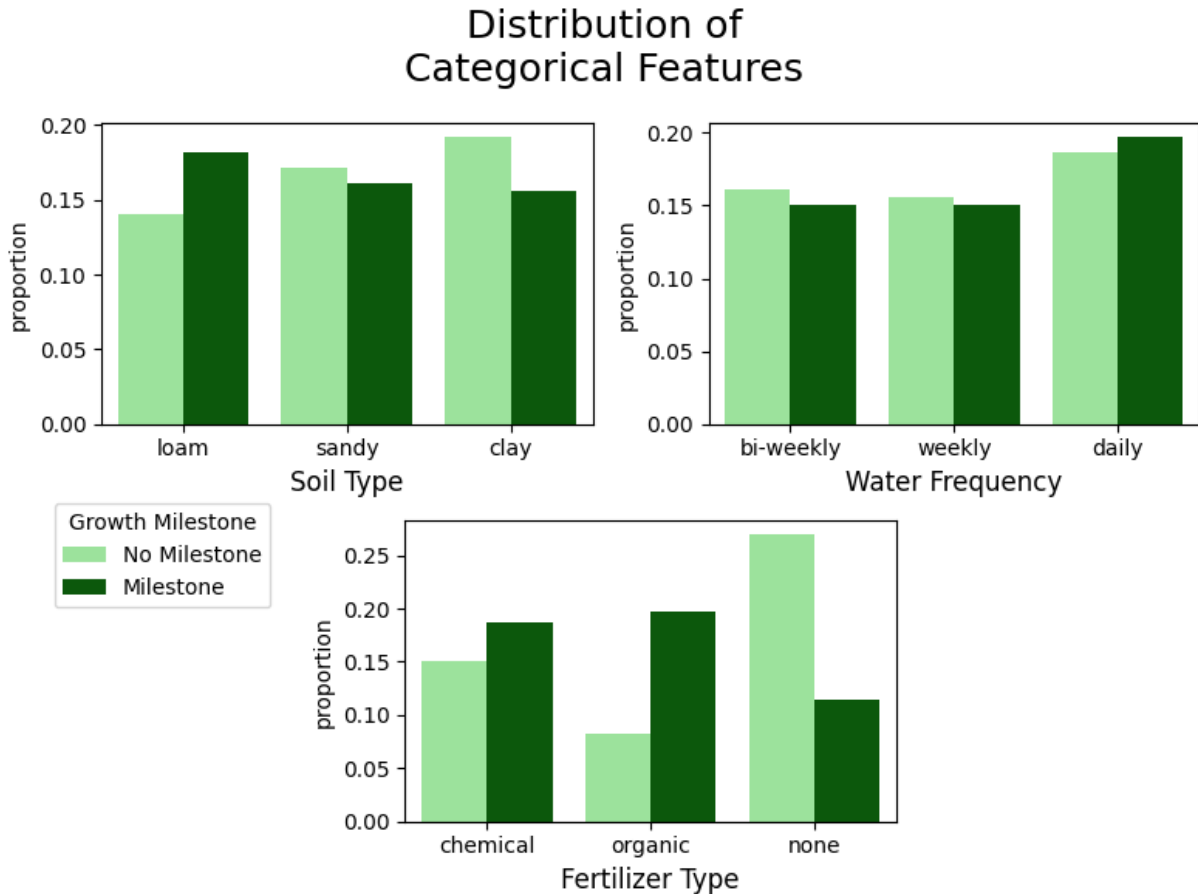


Figura 2: Distribución de los atributos Categóricos según el Crecimiento Significativo

Del gráfico, se puede destacar dos hechos. El atributo de *Soil\_type* tiene un impacto significativo en el crecimiento de las plantas, debido a que los suelos de tipo franco (loam) afecta posi-

vamente este fenómeno, mientras que un suelo de tipo arcilla (clay) tiene el efecto negativo, esto es un indicio de una posible interacción fuerte que repercute en el crecimiento significativo de una planta según el suelo en el que está plantada. Mientras que al atributo *Fertilizer\_Type* muestra un también un impacto en el crecimiento de las plantas, y este hecho es natural debido a que de aquí, la planta, obtiene los diferentes nutrientes para su adecuado crecimiento, siendo así el como favorece al crecimiento de una planta según el fertilizante que se use.

## 4. Metodología del Proyecto

### 4.1. Preprocesamiento

Del análisis realizado en la sección previa, en 3 Análisis Exploratorio de Datos, se puede determinar que es necesario aplicar un adecuado preprocesamiento de los atributos, así cómo también derivar otros que puedan crear otras posibles interacciones. Por lo que se propone realizar lo siguiente:

- **Atributos Numéricos:** Los atributos que se generan los que se obtienen después de aplicar las funciones  $\sqrt{x}$ ,  $\log_{10} x$ ,  $1/x$ ,  $x^2$  y  $x$  (denotando la función identidad), donde  $x$  son los posibles valores que pueden tomar los atributos numéricos. Después de generar los valores, se la aplica la transformación de estandarización en cada uno de los atributos derivados, esto se hace para que los valores estén en un rango de entre  $-3$  y  $3$  o, equivalentemente, estén en unidades estándar.
- **Atributos Categóricos:** Debido a que los atributos pueden tomar tres valores que no tienen una relación de orden plausible o clara, se tiene que realizar una codificación haciendo uso de la codificación One-Hot, para obtener una información más granular sobre las diferentes instancias. Después de esta codificación no se le aplica ninguna otra transformación.

Debido a que el espacio de atributos creció a una dimensión relativamente grande, se tiene que como parte del preprocesamiento se realiza una selección de atributos con el fin de reducir el problema de la dimensionalidad y hacer que los modelos tengan un mejor aprendizaje (capturan las relaciones importantes) mientras se reduce el coste computacional tanto de entrenamiento como de predicción. Para ello:

- **Atributos Numéricos:** Se selecciona los mejores 10 atributos por medio de Mutual Information (MI) [2].
- **Atributos Categóricos:** Se seleccionan los mejores 6 atributos por medio del Estadístico  $\chi^2$  [3].

Ambas métricas permiten medir la misma noción de independencia respecto al target (*Growth\_Milestone*), es decir, se conversan o se usan los atributos que son menos independientes del target con el

fin de que el modelo pueda capturar y aprender estas relaciones.

## 4.2. Modelos de Machine Learning

Para realizar la tarea de clasificación del crecimiento de las plantas se hace uso, principalmente, de modelos que permiten generar o propiciar bordes de decisión no lineales, debido a que, por como se puede observar en 3 Análisis Exploratorio de Datos, las clases del target no son linealmente separables, haciendo que los modelos que hacen uso de bordes de decisión naive o lineales no puedan capturar adecuadamente los patrones en los datos para clasificar una instancia de manera adecuada. Por ello, se hace uso de los siguientes modelos e hiperparámetros a ajustar:

### Support Vector Machine (SVM)

Se usa SVM debido a que es el modelo por ser el principal referente de los modelos que generan bordes de decisión no lineales. De los hiperparámetros que se pueden ajustar según [4], se escogen los siguientes:

- *kernel*:

### Random Forest

### AdaBoost

### Logistic Regression

### K-Nearest Neighbors (KNN)

## 5. Experimentos y Discusión de Resultados

## 6. Análisis de los Resultados

## 7. Conclusiones

## Referencias Bibliográficas

- [1] gorororororo23, *Plant Growth Data Classification*, <https://www.kaggle.com/datasets/gorororororo23/plant-growth-data-classification/data>, 2024.
- [2] scikit-learn developers, *mutual\_info\_classif*, 2025. dirección: [https://scikit-learn.org/stable/modules/generated/sklearn.feature\\_selection.mutual\\_info\\_classif.html](https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.mutual_info_classif.html).
- [3] scikit-learn developers, *chi2*, 2025. dirección: [https://scikit-learn.org/stable/modules/generated/sklearn.feature\\_selection.chi2.html#sklearn.feature\\_selection.chi2](https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.chi2.html#sklearn.feature_selection.chi2).
- [4] scikit-learn developers, *SVC*, 2025. dirección: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html#sklearn.svm.SVC>.